

ML4Finance: Implementazione di modello ibrido BiLSTM-LightGBM per la previsione dei Titoli azionari

FRANCESCO MANNARINO* AND FRANCESCO GIOVANNI LANGÈ¹

Abstract

Questo lavoro propone un modello ibrido BiLSTM-LightGBM per prevedere i prezzi di chiusura giornalieri dell'indice S&P 500. Il modello combina la capacità della BiLSTM di estrarre caratteristiche temporali da dati storici e indicatori tecnici, con l'efficienza predittiva di LightGBM. Addestrato su dati S&P 500 dal 2010 al 2024, il modello ha mostrato buone prestazioni sul set di test (MAE: 0.3643, MSE: 0.2653, RMSE: 0.5151) e un'eccellente capacità di generalizzazione su diversi asset finanziari, inclusi altri indici, azioni e commodities. Questo approccio si dimostra promettente per le previsioni sui mercati finanziari.

1. INTRODUZIONE

La previsione dei movimenti dei mercati finanziari rappresenta da decenni una delle sfide più complesse e affascinanti per ricercatori, investitori e analisti quantitativi. In particolare, l'indice S&P 500, che rappresenta un ampio paniere delle principali aziende statunitensi, è frequentemente utilizzato come riferimento per l'andamento generale del mercato azionario. La sua volatilità, sensibilità a fattori macroeconomici e complessità intrinseca richiedono l'adozione di tecniche di modellazione avanzate per ottenere previsioni affidabili. Negli ultimi anni, i modelli basati sull'apprendimento automatico (Machine Learning) e sull'apprendimento profondo (Deep Learning) hanno mostrato un notevole potenziale nel catturare pattern non lineari nei dati finanziari. Tuttavia, ciascun approccio presenta punti di forza e limiti. I modelli deep learning, come le reti Long Short-Term Memory (LSTM) e le loro varianti bidirezionali (BiLSTM), sono particolarmente efficaci nell'elaborare dati sequenziali e temporali, ma tendono ad essere meno interpretabili e più costosi in termini computazionali. D'altro canto, algoritmi come LightGBM, basato su gradient boosting decision tree, offrono alte prestazioni con una maggiore trasparenza e minore complessità computazionale. In questo lavoro, proponiamo un modello ibrido che combina una rete BiLSTM con LightGBM, un framework di gradient boosting ad alte prestazioni, con l'obiettivo di prevedere i prezzi futuri dell'indice S&P 500. Il modello sfrutta la capacità del BiLSTM di estrarre le feature, che vengono poi utilizzate come input per LightGBM, il quale si occupa della previsione finale. Per addestrare e testare il modello, sono stati utilizzati i dati storici giornalieri dell'S&P 500, dal 1° gennaio 2010 al

31 dicembre 2024. Infine è stata testata la capacità del modello creato di generalizzare, utilizzando come dati di input, altri titoli azionari come indici, azioni e commodities.

2. LAVORI CORRELATI

Negli ultimi anni, i modelli di Deep Learning hanno dimostrato un notevole potenziale nella previsione dei mercati finanziari, grazie alla loro capacità di modellare sequenze temporali complesse e non lineari. L'adozione di tecniche di deep learning, come le reti neurali ricorrenti (RNN), in particolare le Long Short-Term Memory (LSTM) e le Gated Recurrent Unit (GRU), ha permesso di superare i limiti dei modelli statistici tradizionali. Questo ha portato a un crescente interesse nella comunità accademica e finanziaria per l'applicazione di tali metodi, con risultati promettenti.




Figure 1: Funzionamento di una rete LSTM.

*Autore

¹Autore

La sfida principale rimane la capacità di generalizzare i modelli a condizioni di mercato mutevoli e di mitigare il rischio di overfitting, data la natura intrinsecamente rumorosa e non deterministica dei mercati finanziari.

2.1 Deep learning nelle previsioni dei mercati finanziari

Le reti Long Short-Term Memory (LSTM), e in particolare le loro estensioni bidirezionali (BiLSTM), sono state ampiamente adottate per analizzare dati sequenziali, come serie storiche di prezzi, permettendo al modello di apprendere informazioni sia dal passato che dal futuro della sequenza. Tuttavia, l'uso diretto delle LSTM per la previsione può portare a problemi di generalizzazione e overfitting, specialmente in domini ad alta volatilità come i mercati finanziari. Diversi studi hanno proposto l'integrazione di tecniche di feature engineering, tra cui indicatori tecnici, per arricchire il contesto informativo fornito all'algoritmo di apprendimento profondo.




Figure 2: Rete Bidirectional LSTM .

2.2 Modelli ibridi e LightGBM nelle previsioni finanziarie

L'integrazione di modelli di deep learning con algoritmi di machine learning classici è un'area emergente di ricerca. In particolare, il Light Gradient Boosting Machine (LightGBM), proposto da Microsoft nel 2017, è un algoritmo di boosting che ha dimostrato alte prestazioni predittive e grande efficienza computazionale. Il lavoro di Zhao e Khushi (2020) ha mostrato come l'unione tra un CNN ResNet e LightGBM, coadiuvata da tecniche di denoising con wavelet, migliori significativamente la precisione delle previsioni sul mercato Forex.

Sebbene l'integrazione tra CNN e LightGBM sia stata oggetto di studio, l'applicazione combinata di BiLSTM e LightGBM risulta ancora poco esplorata in letteratura, nonostante le potenzialità complementari dei due modelli: la BiLSTM eccelle nell'estrazione di pattern temporali latenti, mentre LightGBM è efficace nel modellare relazioni non lineari e nella gestione dell'overfitting grazie alla sua struttura basata su alberi decisionali.

2.3 Indicatori tecnici nella modellizzazione di serie temporali

Gli indicatori tecnici sono comunemente utilizzati per rafforzare la rappresentazione dei dati nei modelli predittivi finanziari. In particolare, indicatori come RSI, MACD, CCI, ROC, ATR, e Williams %R sono spesso impiegati per fornire segnali su momentum, trend e volatilità del mercato. Nel presente lavoro, tali indicatori sono stati calcolati su finestre mobili di 5, 10 e 20 giorni e normalizzati tramite uno scaler dinamico a 30 giorni, al fine di ridurre l'effetto di scale differenti e rendere i dati più stazionari. Questo arricchimento informativo si è rivelato cruciale per l'efficacia dell'architettura BiLSTM + LightGBM proposta.

3. METODOLOGIA

3.1 Data Preprocessing and Feature Engineering

Il dataset utilizzato in questo studio è composto da dati giornalieri dell'indice azionario S&P 500, ottenuti dal portale Investing.com per il periodo compreso tra il 1° gennaio 2010 e il 31 dicembre 2024. Le informazioni disponibili per ciascun giorno comprendono esclusivamente i prezzi di apertura (open), massimo (high), minimo (low) e chiusura (close), senza includere i volumi di scambio.

Table 1. Prime righe del Dataset.

Data	Chiusura	Apertura	Massimo	Minimo
04/01/2010	1133.0	1116.6	1133.9	1116.6
05/01/2010	1136.5	1132.7	1136.6	1129.7
06/01/2010	1137.1	1135.7	1139.2	1134.0
07/01/2010	1141.7	1136.3	1142.5	1131.3
08/01/2010	1145.0	1140.5	1145.4	1136.2
11/01/2010	1147.0	1146.0	1149.7	1142.0
12/01/2010	1136.2	1143.8	1143.8	1131.8

A partire da queste quattro variabili, sono stati calcolati numerosi indicatori tecnici utilizzati comunemente nell'analisi finanziaria, allo scopo di arricchire la rappresentazione delle caratteristiche del mercato. Gli indicatori utilizzati includono:

1. Momentum e Trend:

- Relative Strength Index (RSI) su 5, 10 e 20 giorni.
- Moving Average Convergence Divergence (MACD) con linea, segnale e istogramma.
- Rate of Change (ROC)
- Commodity Channel Index (CCI)

2. Oscillatori:

- Stochastic Oscillator (slowk, slowd, fastk, fastd)
- Williams %R (su 5, 10 e 20 giorni)

3. Indicatori di Volatilità:

- Average True Range (ATR)
- Normalized ATR (NATR)
- True Range (TRANGE)

Sebbene inizialmente siano state calcolate anche le variazioni percentuali giornaliere (rate of change), queste sono state escluse nella fase finale del preprocessing, ritenendole ridondanti rispetto agli indicatori già considerati. Tutti i dati sono stati normalizzati attraverso uno scaler dinamico applicato su una finestra mobile di 30 giorni. Questa procedura consente di standardizzare ogni feature in funzione del proprio range locale, mantenendo l'informazione relativa alla stagionalità e mitigando la presenza di outlier o cambi strutturali di lungo periodo.

3.2 Architettura BiLSTM

Per catturare le dipendenze temporali nei dati storici dell'S&P 500, è stata utilizzata una rete Bidirectional Long Short-Term Memory (BiLSTM). Questa architettura, grazie alla sua capacità di processare simultaneamente l'informazione in avanti e all'indietro lungo la sequenza temporale, si è dimostrata particolarmente adatta alla modellazione di dinamiche di mercato complesse.

L'input del modello BiLSTM è costituito da finestre sequenziali di $T=30$ giorni, contenenti per ciascun giorno gli indicatori tecnici calcolati e normalizzati. Il modello restituisce una rappresentazione vettoriale compressa che cattura l'informazione evolutiva contenuta in ciascuna finestra temporale.

Per massimizzare le prestazioni, è stata adottata Optuna, una libreria di ottimizzazione automatica degli iperparametri basata su tecniche di ricerca bayesiana. Gli iperparametri ottimizzati includono il numero di neuroni nei layer LSTM, la dimensione del batch, il tasso di dropout e la funzione di attivazione. Il criterio di selezione era basato sulla minimizzazione dell'RMSE sul set di validazione.

Il modello è stato addestrato utilizzando l'ottimizzatore Adam e la Mean Squared Error (MSE) come funzione di loss.

3.3 LightGBM Regression

L'output del modello BiLSTM, che rappresenta un vettore di caratteristiche temporali latenti apprese da serie storiche comprensive di feature tecniche, viene utilizzato come input per un regressore Light Gradient Boosting Machine (LightGBM). In questo approccio, il LightGBM sfrutta rappresentazioni profonde generate dalla BiLSTM a partire da dati storici arricchiti con indicatori tecnici, combinando così l'efficacia dell'apprendimento sequenziale con la capacità predittiva di un modello di boosting su feature latenti.

LightGBM è stato scelto per la sua capacità di gestire dati strutturati, l'efficienza computazionale, e la robustezza nel prevenire overfitting tramite tecniche quali:

- Gradient boosting con alberi decisionali a profondità variabile
- Campionamento di feature e dati
- Utilizzo di istogrammi per accelerare le operazioni di splitting

Il modello finale predice il prezzo di chiusura del giorno successivo. L'output può essere eventualmente riconvertito in variazione percentuale per analisi successive, ma il target durante l'addestramento è stato mantenuto in forma di prezzo assoluto.

4. SETUP DEL MODELLO

In questa sezione vengono descritte le impostazioni utilizzate per l'addestramento del modello ibrido BiLSTM + LightGBM nella previsione del prezzo di chiusura dell'indice S&P 500. In particolare, si riportano i principali iperparametri utilizzati per l'addestramento del modello e le metriche adottate per misurare la qualità delle previsioni.

4.1 Impostazione degli iperparametri

L'ottimizzazione degli iperparametri della rete BiLSTM è stata effettuata tramite la libreria Optuna, mentre per.

4.1.1 Modello BiLSTM

L'input al modello BiLSTM è costituito da una finestra temporale di 30 giorni, ciascuno con 30 feature (shape: (None, 30, 30)).

L'architettura comprende: 3 layer bidirezionali LSTM sequenziali:

- Layer 1: BiLSTM con 256 unità (direzioni forward e backward)
- Layer 2: BiLSTM con 64 unità
- Layer 3: BiLSTM con 112 unità, output senza return_sequences (restituisce solo l'ultimo output temporale)
- Layer denso intermedio con 8 unità e attivazione ReLU

Caratteristiche aggiuntive:

- Funzioni di attivazione LSTM: tanh (attivazione), sigmoid (recurrent_activation)
- Dropout e recurrent dropout: 0.3144
- Bias: abilitato con inizializzazione a zero
- Ottimizzatore: Adam

L'output finale è un vettore di caratteristiche latenti che viene passato come input insieme alle feature tecniche all'algoritmo LightGBM.

4.1.2 Modello LightGBM

Il modello LightGBM è stato configurato come regressore GBDT con i seguenti iperparametri ottimali:

LightGBM riceve in input sia il vettore latente prodotto dal BiLSTM, sia le feature tecniche calcolate sull'ultimo giorno della finestra temporale.

Table 2. *Iperparametri del LightGBM*

Nome Iperparametro	Valore Iperparametro
n_estimators	712
learning_rate	0.0081
max_depth	6
num_leaves	39
colsample_bytree	0.9717
subsample	1
min_child_samples	20
min_child_weight	0.001
reg_alpha (L1)	0.00077
reg_lambda (L2)	0.04478
random_state	42

4.2 Metriche di valutazione

Per valutare le performance del modello, sono state utilizzate tre metriche standard nel contesto della regressione:

- **Mean Absolute Error (MAE):**

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

- **Root Mean Squared Error (RMSE):**

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

- **Mean squared error (MSE):**

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- **Mean Absolute Percentage Error (MAPE):**

$$\text{MAPE} = \frac{1}{N} \sum_{i=1}^N \left| \frac{f(x_i) - y_i}{y_i} \right| \times 100$$

Le metriche sono state calcolate sia sul *validation set* durante l'ottimizzazione con *Optuna*, sia sul *test set* per la valutazione finale.

5. RISULTATI

Per valutare l'efficacia del modello BiLSTM + LightGBM proposto, è stata condotta un'analisi approfondita delle prestazioni sia sul dataset utilizzato per l'addestramento, sia su dataset esterni non visti durante la fase di training. L'obiettivo è stato quello di verificare la capacità del modello di generalizzare e mantenere buone performance predittive anche in presenza di dinamiche di mercato differenti. Tali risultati indicano che l'approccio proposto è in grado non solo di apprendere pattern storici significativi, ma anche di

adattarsi a contesti di mercato diversi, rendendolo un candidato promettente per applicazioni reali.




Figure 3: Previsioni sul validation set.

Il grafico mostra le performance ottenute dal modello ibrido creato messe a confronto con i dati del validation set. Di seguito le metriche di valutazione calcolate sul validation set:

- MAE Validation: 0.4303
- MSE Validation: 0.3205
- RMSE Validation: 0.5661




Figure 4: Previsioni sul test set.

Questo grafico invece mostra quelle ottenute a confronto con i dati del test set. Di seguito le metriche di valutazione calcolate sul test set:

- MAE Test: 0.3643
- MSE Test: 0.2653
- RMSE Test: 0.5151

Infine vengono mostrate le metriche calcolate anche sui dataset di confronto utilizzati e i grafici delle previsioni di alcuni dei dataset di confronto utilizzati (indice, azione, commodity).

Table 3. Metriche di Valutazione sui vari dataset utilizzati

Titolo	MAE	MSE	RMSE
S&P500	0.3643	0.2653	0.5151
FTSE MIB	0.4417	0.3560	0.5522
INTESA	0.4012	0.3049	0.5522
AMAZON	0.4064	0.3217	0.5672
FERRARI	0.4476	0.3217	0.6256
ORO	0.4404	0.3412	0.5841




Figure 5: Previsioni Ftse Mib .




Figure 6: Previsioni Intesa San Paolo .




Figure 7: Previsioni Oro .

6. CONCLUSIONI

In questo lavoro, viene proposto un modello BiLSTM-LightGBM per prevedere il prezzo di chiusura giornaliero del

S&P 500, principale indice azionario del mercato americano e mondiale. È stato dimostrato che le potenzialità complementari del BiLSTM e del LightGBM hanno permesso di effettuare buone previsioni sul prezzo di chiusura di un'indice come l' S&P 500, e dai confronti effettuati, come riesca a generalizzare evitando l'overfitting, essendo performante su altri indici, azioni e commodities. Questa rappresenta un dato molto positivo, poiché dal punto di vista finanziario, questi tre asset, presentano dinamiche di mercato e comportamenti molto differenti, in quanto caratterizzati ognuno da proprie logiche di funzionamento e da pattern di prezzo distintivi. Essere in grado di predire il prezzo in anticipo è molto utile per gli investitori ed i trader. Sebbene questo lavoro abbia ottenuto risultati soddisfacenti, rappresenta un approccio inesplorato che potrebbe essere molto promettente. I risultati sono comunque limitati dall'utilizzo di un dataset non troppo ampio a causa della scarsa potenza di calcolo a disposizione che ha limitato anche il numero di trial eseguiti ed ha ristretto allo stesso tempo lo spazio dei parametri dell'ottimizzatore utilizzato. L'obiettivo per il prossimo futuro è quello di utilizzare questo approccio come punto di partenza per uno studio più approfondito, cercando di migliorare i risultati ottenuti attraverso l'inclusione di altri dati o modelli in grado di tener conto anche dell'impatto delle notizie direttamente correlate al titolo in esame. Miglioria che passa anche dall'aumento della potenza di calcolo a disposizione che permetta sia di utilizzare dataset molto più ampi, sia di sfruttare al meglio la potenza dell'ottimizzatore.

REFERENCES

- [1] BISHOP, C. M. and BISHOP, H. (2023) *Deep Learning: Foundations and Concepts* 1. Springer.
- [2] GOODFELLOW, I., BENGIO, Y. and COURVILLE, A. (2016) *Deep Learning* 1. MIT Press.
- [3] VAZIRI, J., FARID, D. and NAZEMI-ARDAKANI, M. (2023). A time-varying stock portfolio selection model based on optimized PSO-BiLSTM and multi-objective mathematical programming under budget constraints. *Neural Computing and Applications* **35** 18445–18470.
- [4] MURPHY, K. P. (2022) *Probabilistic Machine Learning: An Introduction* 1. MIT Press.
- [5] PRINCE, S. J. D. (2023) *Understanding Deep Learning* 1. MIT Press.
- [6] ZHAO, Y. and KHUSHI, M. (2020). Wavelet Denoised-ResNet CNN and LightGBM Method to Predict Forex Rate of Change. *International Conference on Data Mining Workshops* 385–391.

Francesco Mannarino. Università della Calabria, 252078.

E-mail address: mnnfnc94r31d122u@studenti.unical.it

Francesco Giovanni Langè. Università della Calabria, 259558.

E-mail address: lngfnc99e02d086a@studenti.unical.it